

Prior-Guided Spectral Gating como Framework Geral de Atenção Espectral Interpretável: Generalização entre Modalidades Espectroscópicas (NIR–Raman)

Proposta definitiva de projeto de pesquisa — `pgsg_2`
Segundo projeto derivado do programa de pesquisa sobre Prior-Guided Spectral Gating
(PGSG)

Aluno de Doutorado
Clarimar José Coelho

Programa de Pós-Graduação, Pontifícia Universidade Católica de Goiás (PUC-Goiás)

July 21, 2026

Abstract

O projeto fundador do programa de pesquisa, `pgsg_0`, propôs o *Prior-Guided Spectral Gating* (PGSG), um mecanismo de atenção espectral guiado por priors quimiométricos, validado exclusivamente em espectroscopia no infravermelho próximo (NIR). O projeto `pgsg_1` — *"Prior-Guided Spectral Gating with End-to-End Optimization for NIR Spectroscopy: Scalable Architecture for Interpretable Regression in Small-Sample Regimes"* — atacou a primeira limitação declarada por `pgsg_0` — validação restrita a amostras pequenas — demonstrando, com a base Mango DMC v3 ($n = 1,448$ no protocolo intra-safra), que a arquitetura revisada PGSGv2 (gate por *softmax*, regressor PLS interno reajustado a cada época, prior não-circular via inicialização log-centrada) mantém vantagem preditiva sobre PLS mesmo em larga escala ($R^2 = 0,806$ vs. $0,568$). Este documento apresenta a proposta definitiva de `pgsg_2`, que ataca a segunda limitação declarada: a validação restrita a uma única modalidade espectroscópica. Diferentemente de uma pré-proposta de brainstorming que cogitou generalizar simultaneamente para Raman, infravermelho médio (MIR) e espectrometria de massas (MS), esta proposta delimita o escopo empírico a duas modalidades — NIR (reuso de `pgsg_1`) e Raman (via o benchmark público RamanBench/`raman-data`) — e formaliza um novo constructo, a *topologia do gate espectral*, caracterizada por três descritores quantitativos: entropia, suavidade e esparsidade (índice de Hoyer). MIR e MS são explicitamente descartados do escopo empírico atual por razões de viabilidade e de adequação física do mecanismo, permanecendo como trabalho futuro do programa.

Contents

1	Contexto no programa de pesquisa	1
2	Da pré-proposta à proposta definitiva	2
3	Pergunta científica e hipóteses	2
4	Contribuições	3
5	Bases de dados	3

6	Pré-processamento	4
7	Métodos	4
7.1	Arquitetura	4
7.2	Priors por modalidade	5
7.3	Protocolo experimental	5
7.4	Topologia do gate espectral	5
7.5	Baselines adicionais para H1	5
7.6	Nota: trilha de imageamento hiperespectral (HSI)	6
8	Riscos e limitações	6
9	Cronograma	7
A	Pipeline proposto (detalhamento)	7
B	Referências indicativas	8

1 Contexto no programa de pesquisa

O projeto fundador `pgsg_0` declara cinco limitações (Seção 6), cada uma endereçada por um projeto derivado:

Projeto	Limitação atacada
<code>pgsg_0</code>	— (artigo/projeto fundador; propõe o mecanismo PGSG)
<code>pgsg_1</code>	Escalabilidade (validação restrita a $n = 60\text{--}215$)
<code>pgsg_2</code>	Modalidade única (validação restrita a NIR)
<code>pgsg_3</code>	Alvo único (regressão multi-alvo)
<code>pgsg_4</code>	Otimização sistemática de hiperparâmetros
<code>pgsg_5</code>	Ausência de quantificação de incerteza

`pgsg_1` encerrou-se em estado de submissão (artigo "*Prior-Guided Spectral Gating with End-to-End Optimization for NIR Spectroscopy: Scalable Architecture for Interpretable Regression in Small-Sample Regimes*", formato `elsarticle`, periódico-alvo *Chemometrics and Intelligent Laboratory Systems* — Chemolab). `pgsg_2` reaproveita a arquitetura PGSGv2 e a filosofia de contratos por estágio (operadores $\mathcal{G}, \mathcal{T}, \mathcal{P}, \mathcal{C}, \mathcal{M}, \mathcal{I}_{\text{pred}}, \mathcal{I}_{\text{interp}}, \Sigma$) já implementada e testada em `pgsg_1`.

2 Da pré-proposta à proposta definitiva

A pré-proposta que originou este documento continha um insight central correto: reposicionar o PGSG como um *operador geral de modulação espectral guiado por conhecimento físico/químico*, em vez de uma técnica específica para NIR. Este reposicionamento é mantido. Três decisões de escopo, porém, foram revisadas:

- (a) **Redução de quatro para duas modalidades.** A pré-proposta cogitava NIR, Raman, MIR e MS na mesma investigação. Isso reproduziria, em sentido inverso, o problema que `pgsg_1` corrigiu: uma validação cujo escopo declarado excede o que pode ser executado e testado com rigor dentro do prazo de um projeto. Raman é escolhida como segunda modalidade por (i) possuir um benchmark público de grande escala e recém-disponibilizado (RamanBench, Seção 5), e (ii) apresentar uma estrutura física de pico

(bandas estreitas, alta razão sinal-ruído localizada) que contrasta de forma nítida com as bandas largas e sobrepostas do NIR — o contraste mais informativo para testar a hipótese de topologia de gate.

- (b) **Exclusão de espectrometria de massas do escopo empírico.** O argumento físico que justifica o gating — correlação entre posições espectrais adjacentes ao longo de um eixo contínuo — não se sustenta em MS, cujos sinais são discretos em razão massa/carga sem a mesma estrutura de vizinhança local. Incluir MS sem adaptar a arquitetura seria uma extensão fraca. MS permanece como direção de trabalho futuro, condicionada a uma reformulação do operador de gating para dados não contínuos.
- (c) **Formalização matemática dos descritores de topologia do gate.** As expressões de entropia, suavidade e esparsidade na pré-proposta precisam de correção: o gate real (`PGSGModel`, softmax sobre θ) já soma 1 por construção, então a entropia de Shannon é aplicável diretamente, sem normalização adicional; já a razão de esparsidade proposta na pré-proposta não corresponde a nenhuma medida padrão da literatura de processamento de sinais. A Seção 7.4 apresenta as definições corrigidas.

3 Pergunta científica e hipóteses

Pergunta central: O mecanismo PGSGv2, validado em NIR, generaliza — sem alteração arquitetural — para uma segunda modalidade espectroscópica (Raman), e a topologia do gate aprendido difere sistematicamente entre as duas modalidades de forma consistente com a física subjacente de cada uma?

Hipótese 1 (Generalização sem mudança arquitetural) *PGSGv2, aplicado a dados Raman sem modificação da arquitetura (apenas reconfiguração do prior de inicialização), supera PLS em pelo menos um cenário de regressão do RamanBench, replicando qualitativamente o resultado obtido em NIR ($\Delta R_{PLS}^2 > 0$).*

Hipótese 2 (Esparsidade diferencial) *O gate aprendido em dados Raman apresenta esparsidade (índice de Hoyer) significativamente maior do que o gate aprendido em dados NIR, refletindo a natureza de picos estreitos do espalhamento Raman frente às bandas largas e sobrepostas de sobretons/combinções no NIR.*

Hipótese 3 (Suavidade diferencial) *O gate aprendido em NIR apresenta suavidade (variação total normalizada) significativamente maior do que em Raman, i.e., o gate varia mais abruptamente entre bandas vizinhas no caso Raman.*

Hipótese 4 (Vantagem do prior fisicamente motivado) *A inicialização do gate por atribuições vibracionais da literatura (não derivadas dos dados de treino) produz desempenho preditivo igual ou superior, e maior estabilidade do gate entre sementes de treinamento, em comparação com inicialização não informada, em ambas as modalidades.*

Hipótese 5 (Correlação estrutura-física) *A entropia e a suavidade do gate aprendido correlacionam-se com a largura de banda espectral conhecida das transições vibracionais relevantes para o analito-alvo em cada modalidade.*

4 Contribuições

1. Extensão do mecanismo PGSGv2 para uma segunda modalidade espectroscópica pública (Raman), com reuso do pipeline de oito operadores de `pgsg_1` e mudança mínima de arquitetura.

2. Formalização de três descritores quantitativos da estrutura do gate aprendido — entropia, suavidade, esparsidade — como caracterização reutilizável de *topologia do gate spectral*.
3. Teste falsificável da hipótese de que a topologia do gate reflete a física da modalidade, e não apenas o conjunto de dados específico.
4. Avaliação da robustez do princípio anti-circularidade de prior (estabelecido em `pgsg_1`/ADR correspondente) em um segundo domínio espectroscópico.
5. Extensão dos contratos de estágio (*ingestion, priors*) do pipeline para suportar múltiplas modalidades, preparando a base de código para os projetos subsequentes do programa.

5 Bases de dados

Modalidade	Base	Papel no projeto
NIR	Mango DMC v3 (reuso de <code>pgsg_1</code>); Tecator (âncora de domínio)	Ramo de referência já validado; nenhum reprocessamento de arquitetura necessário.
Raman	<code>bioprocess_substrates</code> (Lange et al., 2026, <i>Measurement</i>), acessado via RamanBench/ <code>raman-data</code> — $n = 6.472$ espectros reais válidos (6.960 originais menos 488 sem rótulo de glicose), 1.870 bandas, eixo 390,63–3384,70 cm^{-1} ; alvo: concentração de glicose	Fonte primária do ramo Raman, definida em ADR-0001 (<code>pgsg_2</code>) e confirmada por execução real na máquina com GPU (16/07/2026).

Nota sobre escala. Diferentemente da pré-proposta original — que temia um regime de amostra tipicamente pequeno em Raman (mediana de 235 espectros entre os 58 datasets de regressão do RamanBench, 87% abaixo de 500 amostras) — o dataset selecionado (`bioprocess_substrates`, $n = 6.960$) está na mesma ordem de grandeza do ramo NIR (Mango DMC v3, $n \approx 12.000$), o que permite testar as Hipóteses 1–5 sem o fator de confusão de escalas de amostra muito diferentes entre modalidades.

Nota sobre execução. O carregamento real (fonte Hugging Face: `chlange/SubstrateMixRaman`) foi executado e validado na máquina com GPU/60 GB RAM em 16/07/2026, confirmando $n = 6.472$ amostras válidas, 1.870 bandas e a presença inequívoca do alvo "glucose" em `target_names` — ver ADR-0001 (`pgsg_2`).

6 Pré-processamento

Modalidade	Etapas de pré-processamento ($\mathcal{T}$)
NIR	Reuso integral do operador $\mathcal{T}$ de <code>pgsg_1</code> : remoção de bandas zeradas por safra (ADR-0005), SNV/derivada conforme protocolo já validado.
Raman	(i) Correção de linha de base (ex.: <i>asymmetric least squares</i> , ALS), necessária pela fluorescência de fundo característica de Raman; (ii) remoção de <i>cosmic rays</i> (picos espúrios de curta largura); (iii) normalização de intensidade (vetor unitário ou SNV); (iv) alinhamento de eixo de deslocamento Raman (cm^{-1}) entre instrumentos, quando aplicável ao dataset selecionado.

Os contratos do operador $\mathcal{T}$ precisam ser estendidos (não reescritos) para aceitar um parâmetro de modalidade que seleciona a cadeia de pré-processamento apropriada, mantendo a mesma interface (`fit_transform` retornando `(X_ndarray, y_ndarray)`) já usada em `pgsg_1`.

7 Métodos

7.1 Arquitetura

Reuso integral do `PGSGModel` de `pgsg_1` (`src/pgsg_1/models/pgsg.py`): gate por *softmax* sobre um vetor $\theta \in \mathbb{R}^p$ ($g = \text{softmax}(\theta)$), regressor interno PLS reajustado a cada época sobre $X \odot g$, e gradiente de θ estimado por diferença finita central (sem autograd). Treino por SGD com momentum e early stopping por *val_loss*. Nenhuma mudança arquitetural é introduzida entre modalidades — esta é, precisamente, a condição de teste da Hipótese 1.

7.2 Priors por modalidade

- **NIR:** prior VIP literatura-informado, conforme já estabelecido em `pgsg_1` (evitando a inicialização circular diagnosticada naquele projeto).
- **Raman:** prior construído a partir de atribuições vibracionais conhecidas da literatura para o(s) analito(s)-alvo do dataset selecionado (ex.: estiramento C=O carboxílico $\approx 1700 \text{ cm}^{-1}$ para ácidos orgânicos), nunca derivado dos dados de treino do próprio experimento.

7.3 Protocolo experimental

Protocolo intra-domínio (*within-dataset*), replicando a decisão de `pgsg_1` de evitar comparações entre domínios heterogêneos sem validação prévia (cf. degradação observada no protocolo cross-safra). Conjunto de teste fixo, disjunto e de tamanho constante por dataset.

7.4 Topologia do gate espectral

Seja $g = \text{softmax}(\theta) \in (0,1)^p$ o vetor de gate aprendido pelo `PGSGModel` sobre p bandas/números de onda. Por construção do softmax, $\sum_{i=1}^p g_i = 1$ e $g_i > 0$ para todo i — logo a entropia de Shannon se aplica diretamente a g , sem normalização adicional.

$$\text{Entropia: } H(g) = - \sum_{i=1}^p g_i \log g_i \quad (1)$$

$$\text{Suavidade (variação total normalizada): } \text{TV}(g) = \frac{1}{p-1} \sum_{i=1}^{p-1} |g_i - g_{i+1}| \quad (2)$$

$$\text{Esparsidade (índice de Hoyer): } S(g) = \frac{\sqrt{p} - \|g\|_1 / \|g\|_2}{\sqrt{p} - 1} \in [0, 1] \quad (3)$$

$S(g) = 0$ corresponde ao gate uniformemente denso; $S(g) = 1$ corresponde a um gate *one-hot*. Esta formalização substitui a razão $\|g\|_2 / \|g\|_1$ da pré-proposta original, que não é uma medida de esparsidade padrão nem tem direção de interpretação definida.

7.5 Baselines adicionais para H1

A comparação central de H1 permanece PGSGv2 vs. PLS. Para aproximar a seção de resultados do estado da arte internacional em atenção espectral, o conjunto de baselines é ampliado com três referências suplementares de desempenho preditivo (não de topologia de gate):

- **ABRN** (*Attention-based Residual Network*, Huang et al., 2019) — rede residual com módulo de atenção aplicada diretamente a espectros NIR brutos, sem seleção manual de variáveis; isola o efeito do prior quimiométrico do PGSGv2 frente a atenção não guiada.
- **SpecFuseNet** (Kabiso & Ko, 2025) — autoencoder residual com atenção de canal (FusedECA) e gate residual espectral (SRG), originalmente proposto para classificação de cultivares por NIR, adaptado aqui para regressão.
- **Baselines lineares esparsos** (Elastic Net, Sparse PLS) — alternativas de seleção de variáveis com interpretabilidade nativa, citadas na literatura de interpretabilidade em NIR; funcionam como ponte entre o baseline linear puro (PLS) e os baselines de atenção profunda.

Esses baselines não alteram o escopo de H1–H5 — continuam centradas em PGSGv2 vs. PLS — e entram apenas como comparação suplementar de desempenho no artigo resultante.

7.6 Nota: trilha de imageamento hiperespectral (HSI)

Uma proposta de financiamento em preparação (CNPq/FNDCT, Chamada Universal 06/2026, Faixa C) associada a este projeto prevê a aquisição de infraestrutura própria — câmera HSI-SWIR e servidor com GPU dedicado — para reduzir a dependência de acesso pontual a equipamento de terceiros e abrir uma terceira frente de validação (dados espacialmente resolvidos). Essa frente é tratada explicitamente como **piloto de infraestrutura, fora do escopo empírico das Hipóteses H1–H5** deste documento: um cubo HSI pode ser tratado como uma coleção de espectros pontuais (um por pixel), permitindo reaproveitar os operadores $\mathcal{G}/\mathcal{T}/\mathcal{P}/\mathcal{M}$ já validados aqui, com extensão natural do operador $\mathcal{I}_{\text{interp}}$ para mapas espaciais de gate — direção que alimenta `pgsg_3` (multi-alvo), não uma hipótese testada em `pgsg_2`.

8 Riscos e limitações

- **Escopo de modalidade:** MIR e MS não fazem parte do escopo empírico deste projeto (Seção 2); resultados não devem ser generalizados além de NIR/Raman sem validação adicional.

- **Tamanho amostral em Raman:** datasets do RamanBench majoritariamente pequenos; comparações estatísticas entre modalidades devem reportar intervalos de confiança e não apenas estimativas pontuais de R^2 .
- **Comparabilidade entre eixos espectrais:** NIR (nm) e Raman (cm^{-1}) não compartilham unidade física direta; os descritores de topologia (Seção 7.4) são adimensionais por construção para permitir comparação, mas a interpretação física de "banda vizinha" difere entre as duas escalas e deve ser discutida explicitamente na seção de resultados.
- **Dataset Raman definido (ADR-0001).** A seleção foi feita por inspeção de metadados, sem download efetivo; o carregamento real do `bioprocess_substrates` e a confirmação de que $n = 6.960$ se mantém após limpeza de dados ficam como primeira etapa de execução na máquina com GPU.

9 Cronograma

Meses	Atividade
1–2	Escopo de dados: inspeção do <code>raman-data</code> e seleção do dataset Raman (concluído — ADR-0001 , <code>bioprocess_substrates</code>); extensão do contrato $\mathcal{G}$ (ingestão) para múltiplas modalidades (em andamento).
3–4	Extensão do operador $\mathcal{T}$ (pré-processamento específico de Raman: ALS, remoção de <i>cosmic rays</i>); testes de contrato.
5–6	Definição do prior fisicamente motivado para Raman (operador $\mathcal{P}$); execução do protocolo experimental intra-domínio para NIR e Raman com PGSGv2 sem alteração arquitetural (operadores $\mathcal{C}, \mathcal{M}, \mathcal{I}_{\text{pred}}$).
7–8	Implementação e cálculo dos descritores de topologia do gate (entropia, suavidade, esparsidade) no operador $\mathcal{I}_{\text{interp}}$; testes estatísticos das Hipóteses 2–5.
9–10	Síntese de resultados (Σ): figuras, tabelas, testes de hipótese consolidados; execução dos baselines suplementares (ABRN, SpecFuseNet, Elastic Net, Sparse PLS — Seção 7.5) para a comparação de desempenho preditivo.
11	Redação do artigo (formato <code>elsarticle</code> , Chemolab), revisão interna.
12	Submissão e resposta a eventuais revisões internas antes de envio.

A Pipeline proposto (detalhamento)

O pipeline mantém a composição estabelecida em `pgsg_1`:

$$\Pi : \mathcal{D} \times \Theta \longrightarrow \mathcal{R}, \quad \Pi = \Sigma \circ \mathcal{I}_{\text{interp}} \circ \mathcal{I}_{\text{pred}} \circ \mathcal{M} \circ \mathcal{C} \circ \mathcal{P} \circ \mathcal{T} \circ \mathcal{G}$$

Operador	Submódulo	Extensão necessária para <code>pgsg_2</code>
$\mathcal{G}$	<code>ingestion</code>	Adicionar carregador para dataset(s) Raman via <code>raman-data</code> ; contrato <code>SpectralDataset</code> ganha valor de <code>metadata[domain] = "raman"</code> , preservando <code>wavelength_unit = cm⁻¹</code> .
$\mathcal{T}$	<code>preprocessing</code>	Nova cadeia de pré-processamento Raman (ALS, remoção de <i>cosmic rays</i> , normalização); interface <code>fit_transform</code> alterada.

Operador	Submódulo	Extensão necessária para <code>pgsg_2</code>
$\mathcal{P}$	<code>priors</code>	Novo tipo de prior: atribuição vibracional literatura-informada (não-VIP), com mesma assinatura de <code>VIPPrior.fit(X, y)</code> por compatibilidade de contrato.
$\mathcal{C}$	<code>scenarios</code>	Reuso direto de <code>ScenarioGenerator</code> ; protocolo intra-domínio (sem cenário cross-modalidade neste projeto).
$\mathcal{M}$	<code>models</code>	Reuso integral de PGSGv2, PLS; nenhuma mudança arquitetural entre modalidades (condição da Hipótese 1).
$\mathcal{I}_{\text{pred}}$	<code>evaluation</code>	Reuso integral; ΔR_{PLS}^2 calculado por modalidade.
$\mathcal{I}_{\text{interp}}$	<code>interpretability</code>	Nova funcionalidade: cálculo de $H(g)$, $TV(g)$, $S(g)$ (Seção 7.4) por modalidade e por semente de treinamento.
Σ	<code>synthesis</code>	Testes de hipótese (Hipóteses 2–5) comparando distribuições de $H(g)$, $TV(g)$, $S(g)$ entre NIR e Raman.

B Referências indicativas

- Koddenbrock, M., Lange, C., Legner, R., Jaeger, M., Kögler, M., et al. *RamanBench: A Large-Scale Benchmark for Machine Learning on Raman Spectroscopy*. arXiv:2605.02003, 2026.
- Echtermeyer, A., Marks, C., Mitsos, A., Viell, J. *Inline Raman spectroscopy and indirect hard modeling for concentration monitoring of dissociated acid species*. Applied Spectroscopy, 75(5), 506–519, 2021.
- Béjar-Grimalt, J., Sánchez-Illana, Á., Quintás, G., Byrne, H. J., Pérez-Guaita, D. *Monte Carlo peaks: simulated datasets to benchmark machine learning algorithms for clinical spectroscopy*. Chemometrics and Intelligent Laboratory Systems, 2025.
- Anderson, N. T., Walsh, K. B., Subedi, P. P. *Mango DMC v3*. Mendeley Data, DOI: 10.17632/46htwnp833.3.
- Huang, L., Guo, S., Wang, Y., Wang, S., Chu, Q., Li, L., Bai, T. *Attention based residual network for medicinal fungi near infrared spectroscopy analysis*. Mathematical Biosciences and Engineering, 16(4), 3003–3017, 2019.
- Kabiso, A. C., Ko, C.-H. *Attention-enhanced residual autoencoder for NIR spectral feature extraction and classification of grain varieties*. Scientific Reports, 15, 32750, 2025.